

Tarea 2

Alumno: Luna Arellano Maria Fernanda

Profesor: Ing. Fernando Arreola Franco

Grupo: 1

Semestre: 2027-1

1. Modelo Vectorial

Representa información mediante vectores (conjuntos ordenados de números) para facilitar comparaciones y operaciones matemáticas. Fundamental en IA, Machine Learning y procesamiento de lenguaje natural.

- Ventajas: Excelente para grandes volúmenes de datos, Machine Learning y búsqueda por similitud.
- Desventajas: Puede perder significado original al enumerar, generar vectores gigantescos y consumir muchos recursos.

Casos de uso: Motores de búsqueda y sistemas de recomendación (ej. tiendas en línea).

Software implementado: FAISS, Milvus, Pinecone, Weaviate, Qdrant, Chroma.

Modelos de Big Data

2. Modelo Distribuido

Distribuye datos y procesamiento entre varios servidores para superar las limitaciones de una sola máquina.

- Ventajas: Escalabilidad horizontal alta, tolerancia a fallos y procesamiento en paralelo.
- Desventajas: Alta complejidad administrativa, costos elevados y posibles problemas de red entre equipos.

Casos de uso: Procesamiento a gran escala, análisis masivo y aplicaciones web con millones de usuarios.

Software: Apache Hadoop, Apache Spark, Apache Flink.

3. Modelo de Procesamiento por Lotes (Batch)

Acumula datos durante un período de tiempo para procesarlos en grupo (lotes) posteriormente, sin requerir inmediatez.

- Ventajas: Eficiente en recursos con grandes volúmenes y altamente automatizable.
- Desventajas: No apto para datos en tiempo real; los resultados no son inmediatos.

Casos de uso: Generación de reportes nocturnos, análisis de ventas históricas y respaldos.

Software: Apache Hadoop, Apache Spark, Apache Hive.

4. Modelo de Procesamiento en Tiempo Real

Procesa los datos instantáneamente conforme se generan para reaccionar de inmediato.

- Ventajas: Respuestas rápidas, soporte para toma de decisiones al instante y detección inmediata de eventos.
- Desventajas: Alta complejidad de implementación, infraestructura costosa y sensibilidad a errores continuos.

Casos de uso: Detección de fraudes, monitoreo de sistemas, redes sociales y análisis financiero.

Software: Apache Kafka, Apache Flink, Apache Storm, Spark Streaming.

5. Modelo Data Lake

Almacena grandes volúmenes de datos en su formato original (estructurados, semiestructurados o no estructurados) sin organización previa obligatoria.

- Ventajas: Gran flexibilidad, capacidad multiformato y apto para futuros proyectos de IA.
- Desventajas: Riesgo de convertirse en un repositorio desordenado ("pantano de datos") y mayor dificultad en seguridad y gobernanza

Casos de uso: Almacenamiento masivo multipropósito para análisis avanzado, Business Intelligence e IA.

Software: Amazon S3, Azure Data Lake Storage, Google Cloud Storage, Hadoop HDFS.

6. Modelo Data Warehouse

Almacena información estrictamente organizada, estructurada y procesada previamente para facilitar consultas analíticas complejas.

- Ventajas: Excelente rendimiento para análisis histórico, reportes precisos y apoyo a la toma de decisiones empresariales.
- Desventajas: Rigidez estructural, costos elevados de diseño e implementación y necesidad previa de preparación de datos.

Casos de uso: Análisis corporativo de ventas, finanzas, inventarios y métricas de rendimiento (BI).

Software: Snowflake, Google BigQuery, Amazon Redshift, Microsoft Azure Synapse Analytics, Oracle Autonomous Data Warehouse.